Πίνακες κατακερματισμού

Ένας πίνακας κατακερματισμού (hash table) αποθηκεύει ζεύγη κλειδί–τιμή και υποστηρίζει εισαγωγή, αναζήτηση και διαγραφή σε μέσο χρόνο O(1). Είναι η δομή πίσω από τα dict της Python και τα HashMap της Java.

- Μια συνάρτηση κατακερματισμού h(k) μετατρέπει το κλειδί k σε θέση του πίνακα, από 0 έως m − 1.
- Σήμερα: συναρτήσεις κατακερματισμού, συγκρούσεις, αλυσίδες, ανοιχτή διευθυνσιοδότηση, συντελεστής φόρτου.

Συναρτήσεις κατακερματισμού

Μια καλή συνάρτηση κατακερματισμού κατανέμει τα κλειδιά ομοιόμορφα στις θέσεις του πίνακα και υπολογίζεται γρήγορα.

- Μέθοδος διαίρεσης: $h(k) = k \bmod m$. Το m καλό είναι να είναι πρώτος αριθμός, όχι κοντά σε δύναμη του 2.
- Για συμβολοσειρές συνδυάζουμε όλους τους χαρακτήρες, π.χ. πολυωνυμικά: $h(s) = (s_0 \cdot 31^{n-1} + \ldots + s_{n-1}) \bmod m$.
- Η ίδια είσοδος πρέπει να δίνει πάντα την ίδια θέση· διαφορετικές είσοδοι μπορούν να δώσουν την ίδια θέση.

Συγκρούσεις και αλυσίδες

Σύγκρουση (collision) έχουμε όταν δύο διαφορετικά κλειδιά παίρνουν την ίδια θέση. Επειδή τα πιθανά κλειδιά είναι πολύ περισσότερα από τις θέσεις, οι συγκρούσεις είναι αναπόφευκτες.

- Αλυσίδες (chaining): κάθε θέση κρατά μια λίστα με όλα τα στοιχεία που κατέληξαν εκεί.
- Συντελεστής φόρτου α = n / m, όπου n τα στοιχεία και m οι θέσεις. Με αλυσίδες, η μέση αναζήτηση κοστίζει O(1 + α).
- Χειρότερη περίπτωση O(n): όλα τα κλειδιά στην ίδια αλυσίδα.

Ανοιχτή διευθυνσιοδότηση

Στην ανοιχτή διευθυνσιοδότηση (open addressing) όλα τα στοιχεία μένουν μέσα στον πίνακα. Αν η θέση είναι πιασμένη, δοκιμάζουμε άλλες θέσεις με συγκεκριμένη σειρά.

- Γραμμική δοκιμή: h(k), h(k)+1, h(k)+2, … Απλή, αλλά δημιουργεί «συστάδες» (primary clustering).
- Τετραγωνική δοκιμή: h(k)+1², h(k)+2², … Μειώνει τις συστάδες.
- Διπλός κατακερματισμός: το βήμα δίνεται από δεύτερη συνάρτηση $h_2(k)$.
- Εδώ πρέπει α < 1· στην πράξη κρατάμε α κάτω από 0,7 περίπου.

Αναδιάταξη (rehashing)

Όταν ο συντελεστής φόρτου ξεπεράσει ένα όριο, φτιάχνουμε νέο πίνακα περίπου διπλάσιου μεγέθους και ξαναεισάγουμε όλα τα στοιχεία.

- Μία αναδιάταξη κοστίζει O(n), αλλά συμβαίνει σπάνια· το αποσβεσμένο κόστος ανά εισαγωγή μένει O(1).

Πράξη	Μέσος χρόνος	Χειρότερος χρόνος
Αναζήτηση	O(1)	O(n)
Εισαγωγή	O(1) αποσβεσμένο	O(n)
Διαγραφή	O(1)	O(n)

Σύνοψη

- Hash table: κλειδί → θέση μέσω h(k), μέσος χρόνος O(1).
- Οι συγκρούσεις λύνονται με αλυσίδες ή με ανοιχτή διευθυνσιοδότηση.
- Ο συντελεστής φόρτου α καθορίζει την απόδοση· όταν μεγαλώσει, κάνουμε rehashing.
- Οι hash tables δεν κρατούν σειρά: για ταξινομημένη διάσχιση χρειάζεται δέντρο.

Για την επόμενη φορά: υλοποιήστε πίνακα κατακερματισμού με αλυσίδες και μετρήστε το μέσο μήκος αλυσίδας για α = 0,5, 1 και 2.